

Plan Praktikum Peter 2026

1. Vorüberlegungen

1.1 Benutzerinteresse

- Welche Fragen stellen Studieninteressierte und Erstsemestler am häufigsten
- Welchen Mehrwert soll der Chatbot den Endnutzer bringen
- Wie viele Bereiche soll der Chatbot abdecken

1.2 Bibliotheken und Runtime

- Welche Sprachen und Runtimes nutze ich: NodeJS und Python
- Welche Bibliotheken nutze ich und brauche ich: Pytorch, Fastify etc.

1.3 IT-Sicherheit

- Wie sichere ich den Server vor Angreifern?
- Wie schütze ich den Chatbot und Nutzer vor Prompt-Injection?
- Wie viele Freiheiten gebe ich den Nutzer?
- Gibt es eine langzeitarchivierte Chathistory und wenn ja wo speichere ich sie?

1.4 Hosting bzw. Serverbetrieb

- Wo soll der Chatbot verfügbar sein (Internet oder HTWK-eigenes Intranet)?
- Auf welchen Server läuft der Chatbot
- Wie viele Ressourcen stehen dem Betrieb zur Verfügung

1.5 Rechtliches und Lizenzen

- Unter welchen Rechten läuft die Nutzung des gewählten Modells (welche Lizenzen)?
- Unter welchen Rechten läuft die Nutzung von Trainingsdaten (welche Lizenzen)?

1.6 Basismodellauswahl

- Welches Modell eignet sich gut für alle Anforderungen als Basismodell?
- Wie leistungsstark ist das betrachtete Modell?
- Wie gut liegt das betrachtete Modell im Ranking gegenüber anderen?
- Wie viele Parameter hat es und welche Hardwareanforderungen sind benötigt?

1.7 Aufwand und Risiken

- Wie viel Aufwand bringt die Planung?
- Wie viel Aufwand bringt das Finetuning?
- Wie viel Aufwand bringt das Hosting und die Infrastruktur?
- Wie viel Aufwand bringt die Instandhaltung
- Welche potentiellen Risiken gehen mit dem Plan einher?

2. Datagrapping

2.1 Ziel:

Das Erlernen von genauen Informationen zur der HTWK Leipzig.

A Reines Finetuning:

2A.1 Übersicht:

Ansammeln von DS-Daten (Domain Specific bzw. HTWK Daten) und das Umwandeln derer in Chat-Templates durch ein lokales Modell.

2A.2 Ablauf:

1. Sammeln von HTWK-spezifischen Daten (Vorlesungen etc.)
2. Semantische Aufteilung dieser Daten
3. Generierung von Trainingsdaten im Chat-Template Format durch ein lokales Modell
4. Überfliegen der Trainingsdaten durch eine Person bzw. ein lokales Modell (→ evtl. Verbesserung)
5. Splitten der Trainingsdaten in Trainings- und Validierungsdaten
6. Finetuning

2A.3 Produkt:

Modell **Version 0.1.0** mit spezifischen Daten in den Gewichten des Modells

B Vektordatenbank:

2B.1 Übersicht:

Ansammeln von DS-Daten (Domain Specific bzw. HTWK Daten) und das erstellen einer Vektordatenbank mithilfe eines lokalen Modells.

2B.2 Ablauf:

1. Sammeln von HTWK-spezifischen Daten (Vorlesungen etc.)
2. Semantische Aufteilung dieser Daten
3. Generierung einer Vektordatenbank durch ein lokales Modell (z.B. bge-m3)
4. Splitten der Trainingsdaten in Trainings- und Validierungsdaten

2B.3 Produkt:

Vektordatenbank mit spezifischen Daten

3. Schreiben von Chat-Templates

3.1 Ziel:

Das Erlernen der richtigen Form der Antwort und dem richtigen Umgang bzw. Ausdruck mit dem Nutzer.

3.2 Übersicht:

Das manuelle Schreiben von Trainingsdaten im Chat-Template Format.

3.3 Ablauf:

1. Definierung der Eigenschaften des Chatbots
2. Auf *Schritt 1*. Basierende Planung der Reihenfolge (nach dem Prinzip wichtigstes zuerst und zuletzt)
3. Schreiben der Trainingsdaten
4. Splitten der Trainingsdaten in Trainings- und Validierungsdaten
5. Finetuning des KI-Modells (**Version [2.1] 0.1.0 [2.2] 0.0.0**) in eventueller Beachtung der Vektordatenbank abhängig von 2.x

3.4 Produkt:

Modell **Version [2.1] 0.2.0 [2.2] 0.1.0**

4. Präsentation

4.1 Ziel:

Das Präsentieren meiner Ziele, Arbeitsweise und Ergebnisse, sowie das Einführen in das KI-Finetuning

4.2 Mindestbenötigter Inhalt:

- Mein Ziel
- Meine Arbeitsweise
- Meine Probleme und deren Lösungen
- Das Ergebnis
- Wie funktioniert ein Transformermodell bzw. Chatbot grundsätzlich
- Wie funktioniert das KI-Training
- Wie kann man es weiterentwickeln - Zukunftsausblicke